Análise exploratória e pré-processamento: Titanic

Dataset Titanic: UA 1 e 2

Disciplina: Análise e Visualização de Dados
Equipe: Diogo Galrão Carvalho; Felipe Artur Macedo Lima; Luan Cavalcante Dias Rodrigues
Repositório: github.com/luang1t/hands-on-eda
Notebook: notebooks/01_analise_titanic.ipynb

1. Introdução

A base Titanic contém 891 passageiros e 12 colunas. O objetivo é descrever a sobrevivência, examinar relações entre variáveis e preparar uma versão numérica para análises posteriores. Os registros são uma amostra do conjunto de passageiros; as associações observadas não estabelecem causas.

2. Classificação e qualidade dos dados

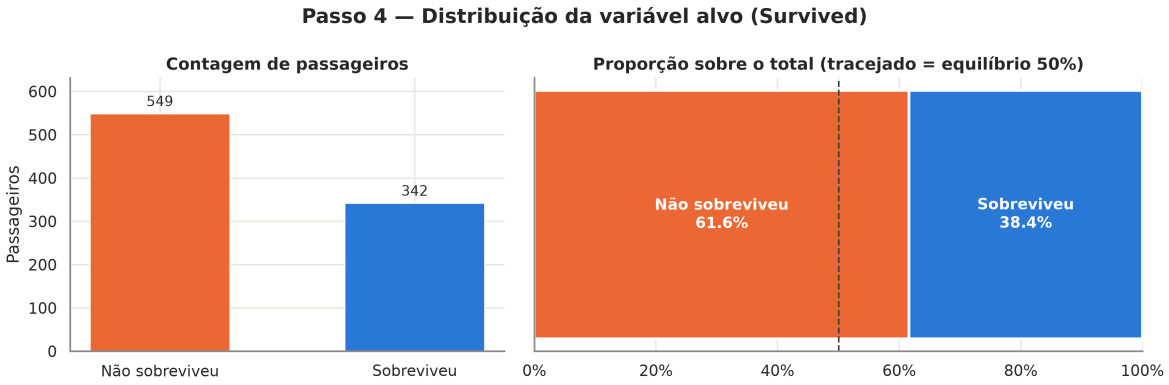
Variável	Tipo e subtipo	Papel e justificativa
`PassengerId`	Qualitativa nominal	Identificador; o número não é uma medida.
`Survived`	Qualitativa nominal binária	Alvo: 0 para não sobrevivente e 1 para sobrevivente.
`Pclass`	Qualitativa ordinal	Classe com ordem, sem distância numérica conhecida entre categorias.
`Name`	Qualitativa nominal	Nome de identificação, com texto individual.
`Sex`	Qualitativa nominal	Categoria de sexo registrada na base.
`Age`	Quantitativa contínua	Idade em anos, inclusive frações.
`SibSp`	Quantitativa discreta	Contagem de irmãos e cônjuges a bordo.
`Parch`	Quantitativa discreta	Contagem de pais e filhos a bordo.
`Ticket`	Qualitativa nominal	Código do bilhete, com alta cardinalidade.
`Fare`	Quantitativa contínua	Tarifa registrada.
`Cabin`	Qualitativa nominal	Código de cabine, com alta proporção de ausências.
`Embarked`	Qualitativa nominal	Porto de embarque, sem ordem entre categorias.

Variáveis numéricas admitem medidas de posição e dispersão; categorias são resumidas por frequências. A base tem 177 idades ausentes (19,9%), 687 cabines ausentes (77,1%) e dois portos ausentes. Não há linhas integralmente duplicadas. As 15 tarifas zero foram mantidas: o registro isolado não permite determinar a causa de cada uma.

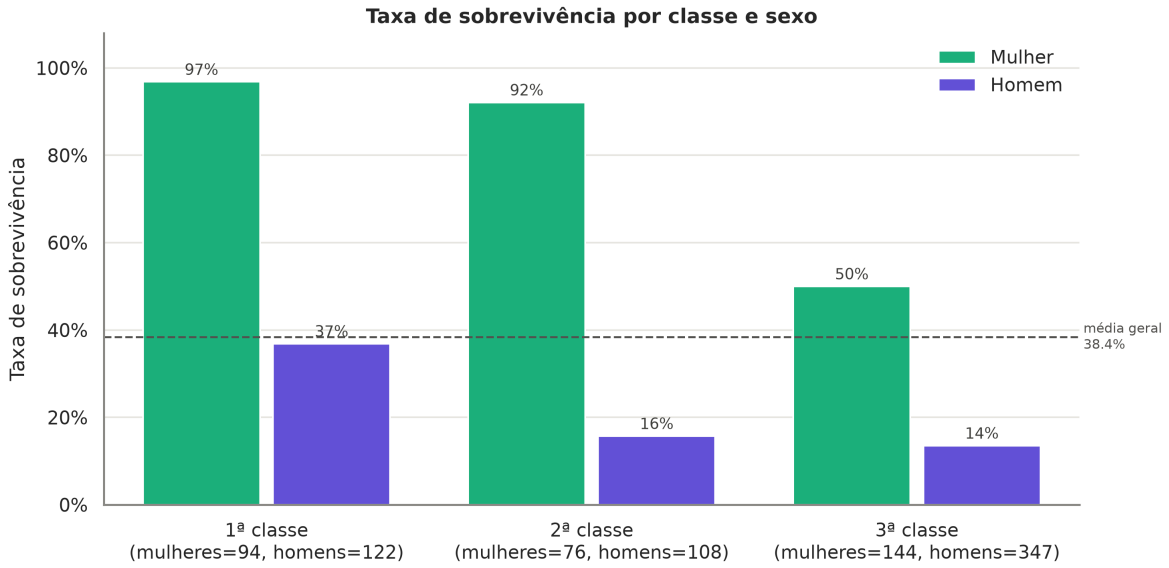
3. Estatística descritiva e sobrevivência

A idade tem média de 29,7 anos, mediana de 28 e varia de 0,42 a 80 anos. A tarifa tem média de 32,2, mediana de 14,45 e máximo de 512,33, com cauda à direita. `SibSp` e `Parch` têm mediana zero e máximos 8 e 6, respectivamente.

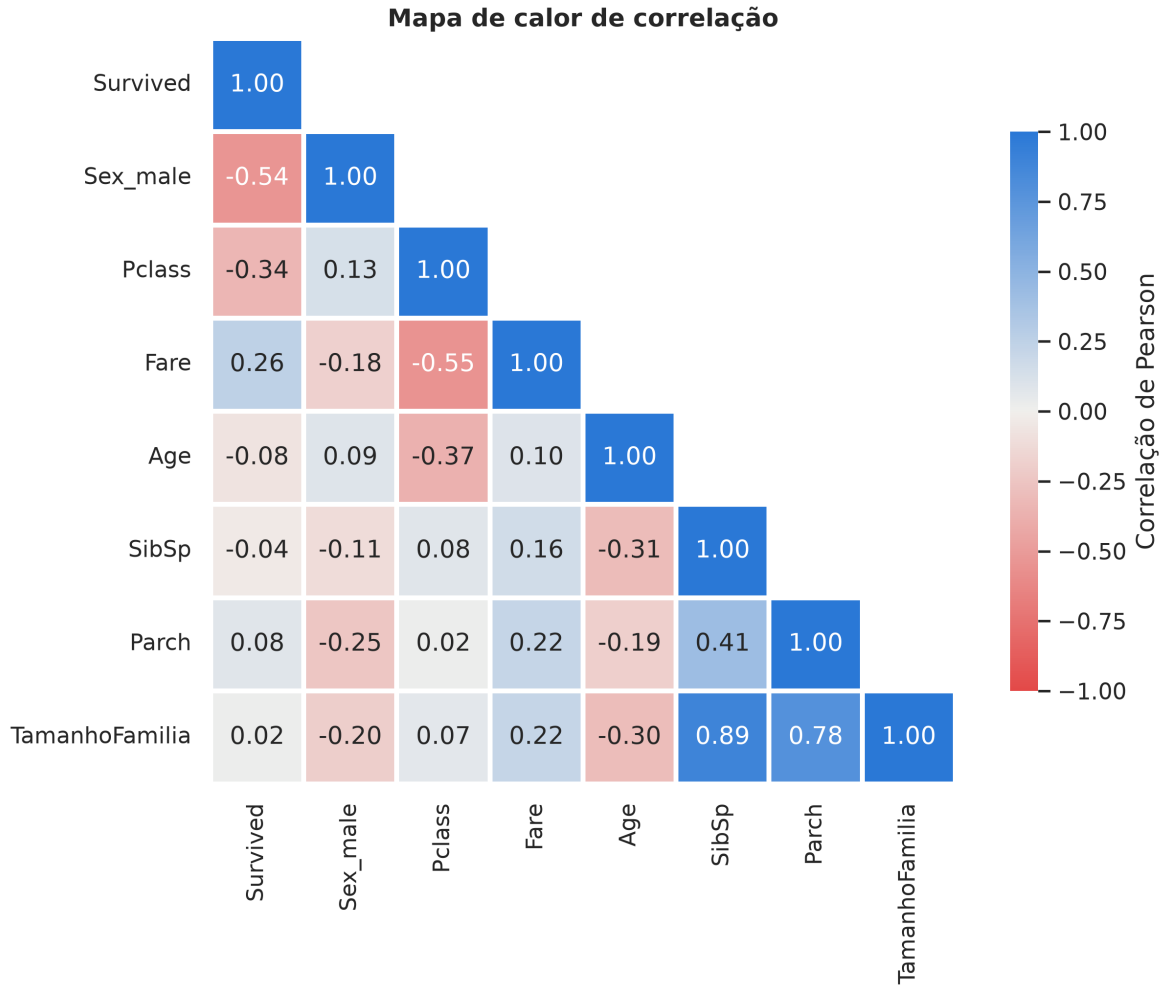
Dos 891 registros, 342 sobreviveram (38,38%) e 549 não sobreviveram (61,62%). Um classificador que sempre escolha a classe mais frequente alcançaria 61,62% de acurácia. Por isso, uma avaliação futura deve incluir matriz de confusão, precisão e revocação, além da acurácia.



A sobrevivência foi de 74,2% entre mulheres e 18,9% entre homens. Na primeira classe foi de 63,0%, na segunda 47,3% e na terceira 24,2%. A comparação conjunta mostra 96,8% entre mulheres da primeira classe e 50,0% entre mulheres da terceira; entre homens, 36,9% e 13,5%, respectivamente. Sexo e classe estão associados ao resultado, mas os dados não isolam o efeito causal de cada variável.



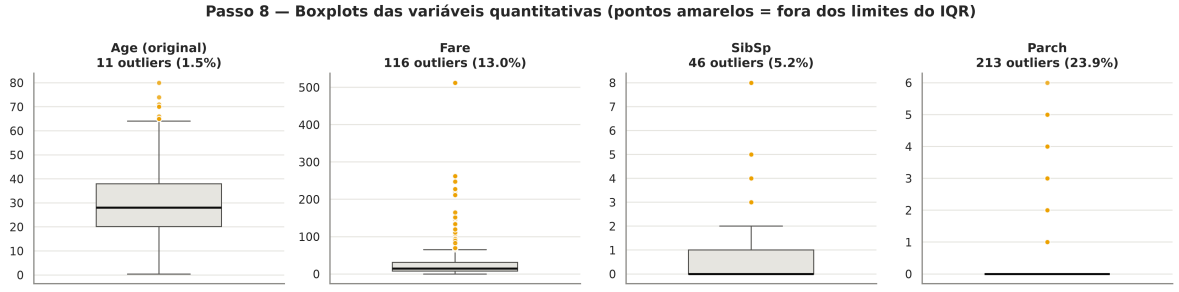
O mapa de calor resume associações lineares e deve ser interpretado junto dos gráficos de grupos. Ele não capta todas as relações não lineares nem estabelece causalidade.



4. Ausências, valores extremos e transformações

Para `Age`, a mediana por sexo e classe preserva diferenças entre grupos melhor que uma mediana única, embora reduza a variabilidade; `IdadeImputada` sinaliza as 177 substituições. `Embarked` recebe a moda, uma escolha simples para duas observações, mas não confirma o porto real. `Cabin` é substituída por `TemCabine`, indicador de registro, pois imputar um código específico não teria suporte. A ausência pode refletir o processo de registro, sem comprovar que o passageiro não tinha cabine.

A regra de 1,5 intervalo interquartil sinalizou 11 valores em `Age`, 116 em `Fare`, 46 em `SibSp` e 213 em `Parch`. Em `Parch`, o intervalo interquartil é zero, então a regra sinaliza qualquer valor positivo. Valores sinalizados não são necessariamente erros. As linhas foram mantidas por não haver evidência suficiente para removê-las.



O notebook divide `Fare` pela quantidade de registros com o mesmo `Ticket` e aplica `log1p`, reduzindo a influência de tarifas altas. O resultado é uma estimativa exploratória: tarifa repetida não comprova o preço individual, e a amostra pode omitir outros ocupantes do bilhete. `SibSp` e `Parch` formam faixas de tamanho familiar. `PassengerId`, `Name`, `Ticket` e as colunas substituídas são retirados da matriz final.

`Sex`, `Embarked` e a faixa familiar recebem One-Hot Encoding, que não impõe uma ordem artificial às categorias nominais; a primeira categoria serve de referência. `Pclass` mantém a ordem. `Age` e a tarifa transformada são padronizadas por média e desvio padrão, equivalentes ao cálculo do `StandardScaler`. Essa escala ajuda modelos baseados em distância ou regularização; árvores não precisam dela.

5. Resultado e limites

O arquivo `data/processed/titanic_clean.csv` contém 891 linhas e 11 colunas numéricas, sem ausências. Ele descreve o processamento de toda a amostra. Para avaliação preditiva, é necessário separar treino e teste antes de ajustar imputação, categorias e escala; usar o CSV já transformado para essa avaliação causaria vazamento de informação.

Métrica Analítica	Valor Observado
Total de Passageiros Analisados	891
Sobreviventes	342 (38.38%)
Não Sobreviventes (Óbitos)	549 (61.62%)
Taxa de Sobrevivência Feminina	74.20%
Taxa de Sobrevivência Masculina	18.89%
Taxa Sobrevivência - 1ª Classe	62.96%
Taxa Sobrevivência - 2ª Classe	47.28%
Taxa Sobrevivência - 3ª Classe	24.24%
Nulos Iniciais em Cabine (Cabin)	687
Nulos Iniciais em Idade (Age)	177
Nulos Iniciais em Embarque (Embarked)	2
Dimensão do Dataset Limpo	891 linhas × 11 colunas

Referências

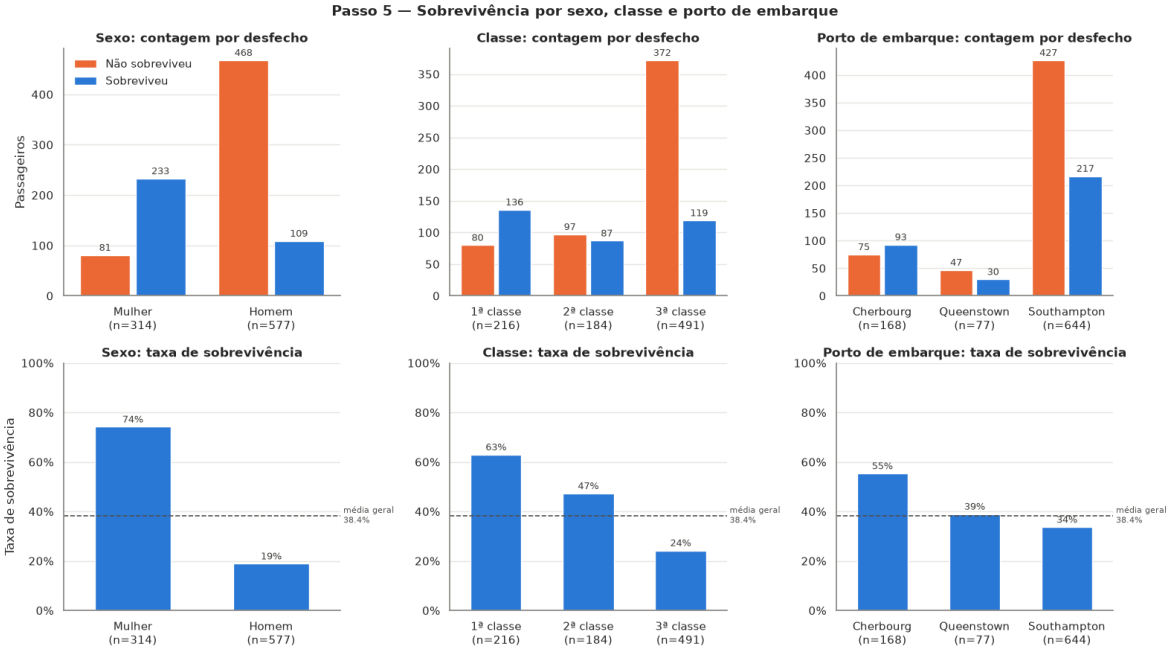
KAGGLE. Titanic Dataset. Disponível em: https://www.kaggle.com/datasets/yasserh/titanic-dataset. Acesso em: 5 nov. 2026.

PEDREGOSA, Fabian et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825-2830, 2011.

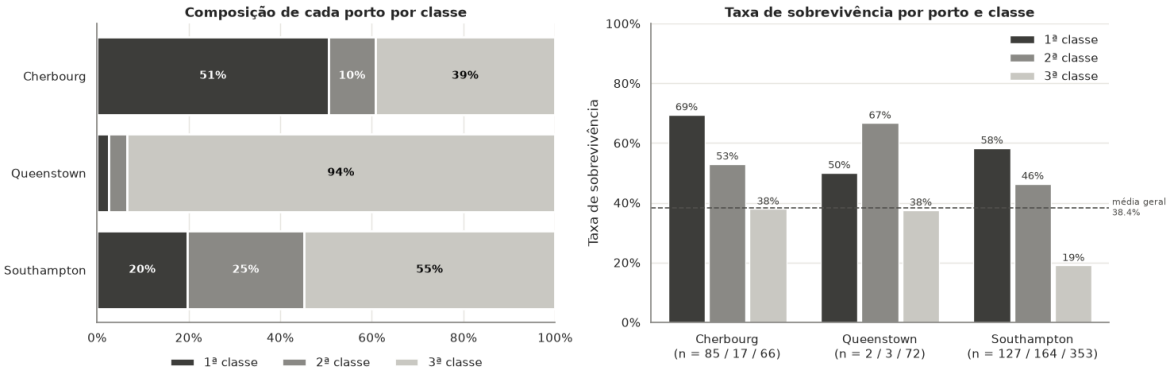
Apêndice: demais gráficos do notebook

Os gráficos complementam as comparações e o tratamento descritos acima. As taxas por grupo devem ser lidas com os tamanhos das amostras; grupos menores são menos estáveis.

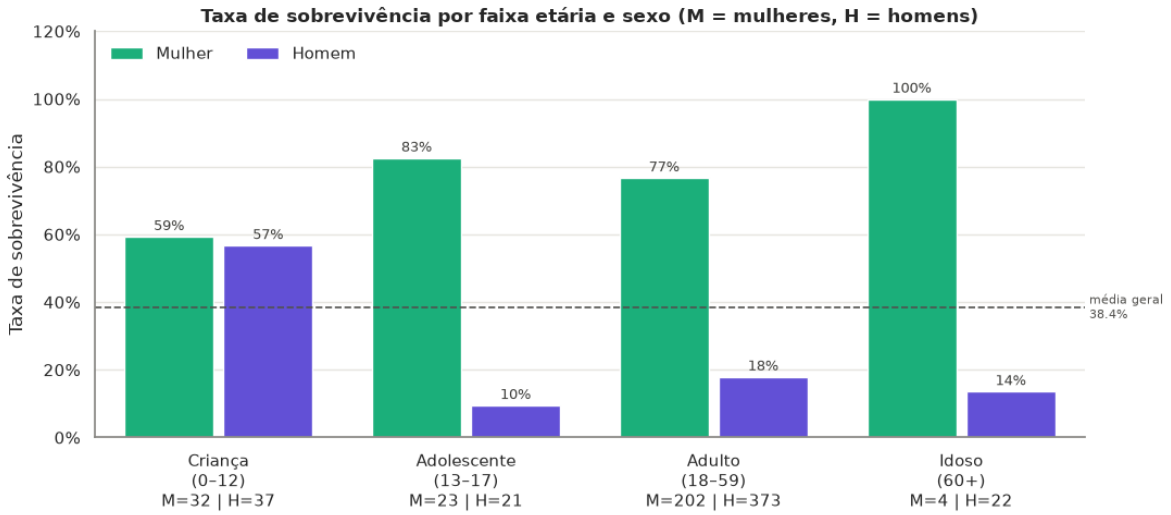
Sobrevivência por categoria



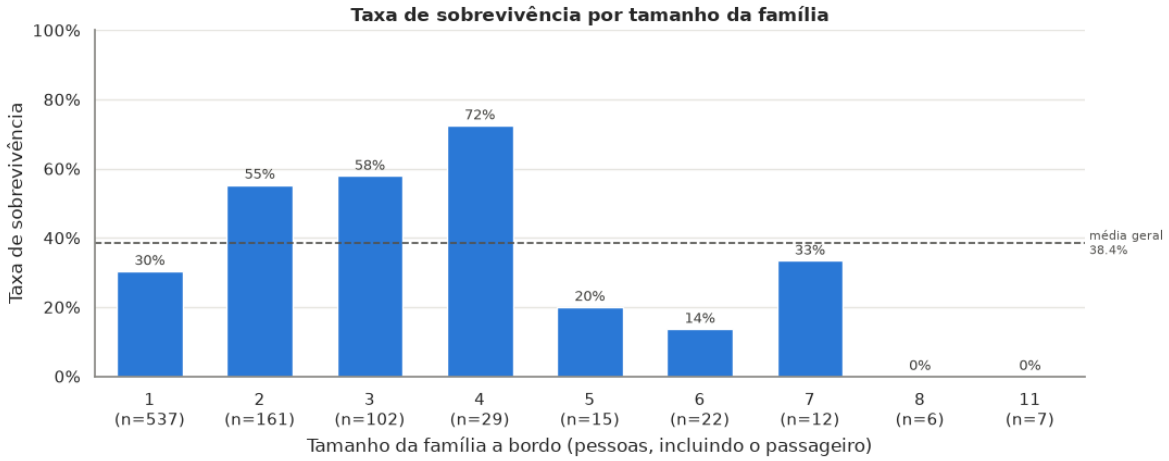
Porto de embarque e classe



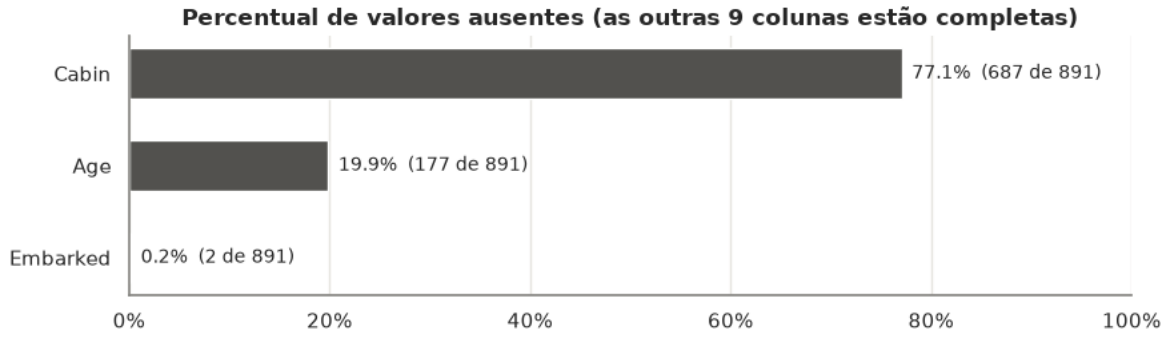
Idade, sexo e sobrevivência



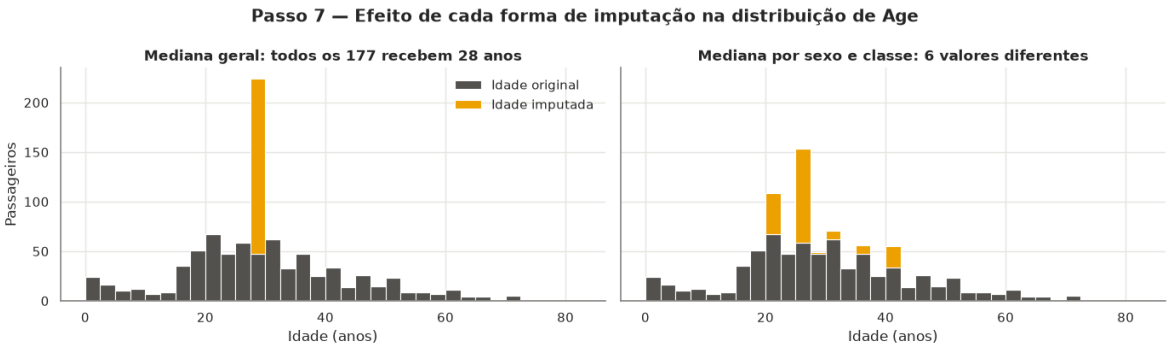
Tamanho da família e sobrevivência



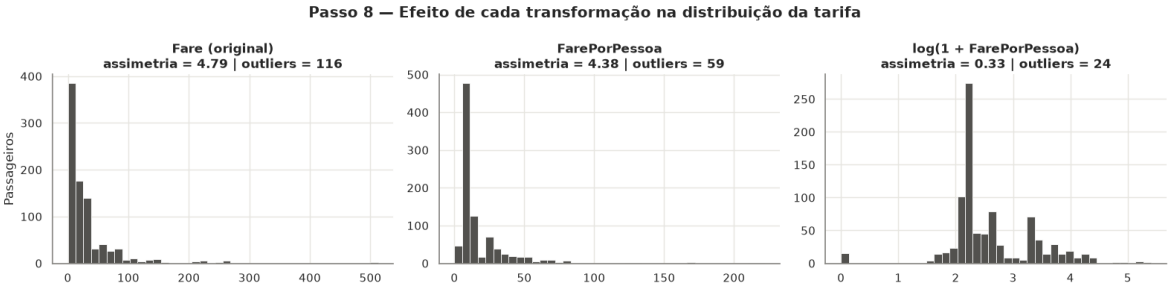
Valores ausentes



Imputação de idade



Transformação da tarifa estimada



Comparação de escalas

