Engenharia de recursos e visualização: House Prices

Dataset House Prices: UA 3 e 4

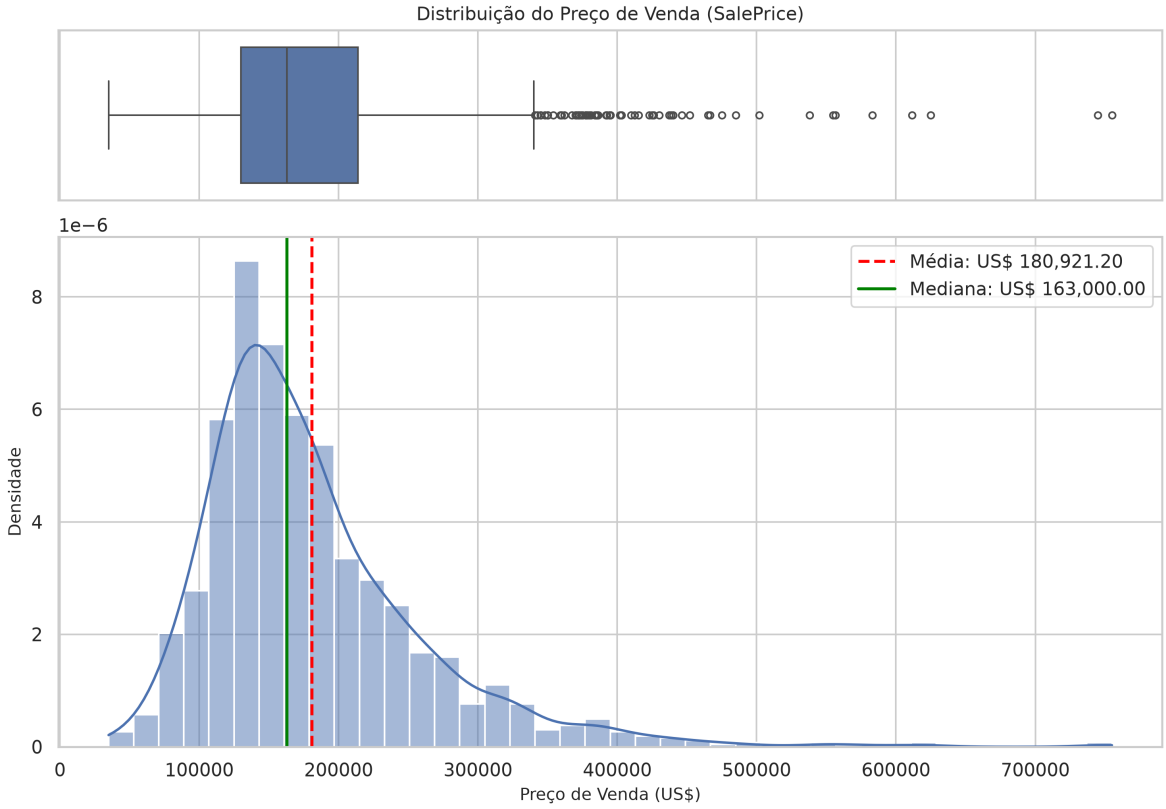
Disciplina: Análise e Visualização de Dados
Equipe: Diogo Galrão Carvalho; Felipe Artur Macedo Lima; Luan Cavalcante Dias Rodrigues
Repositório: github.com/luang1t/hands-on-eda
Notebook: notebooks/02_engenharia_recursos_house_prices.ipynb

1. Dados e objetivo

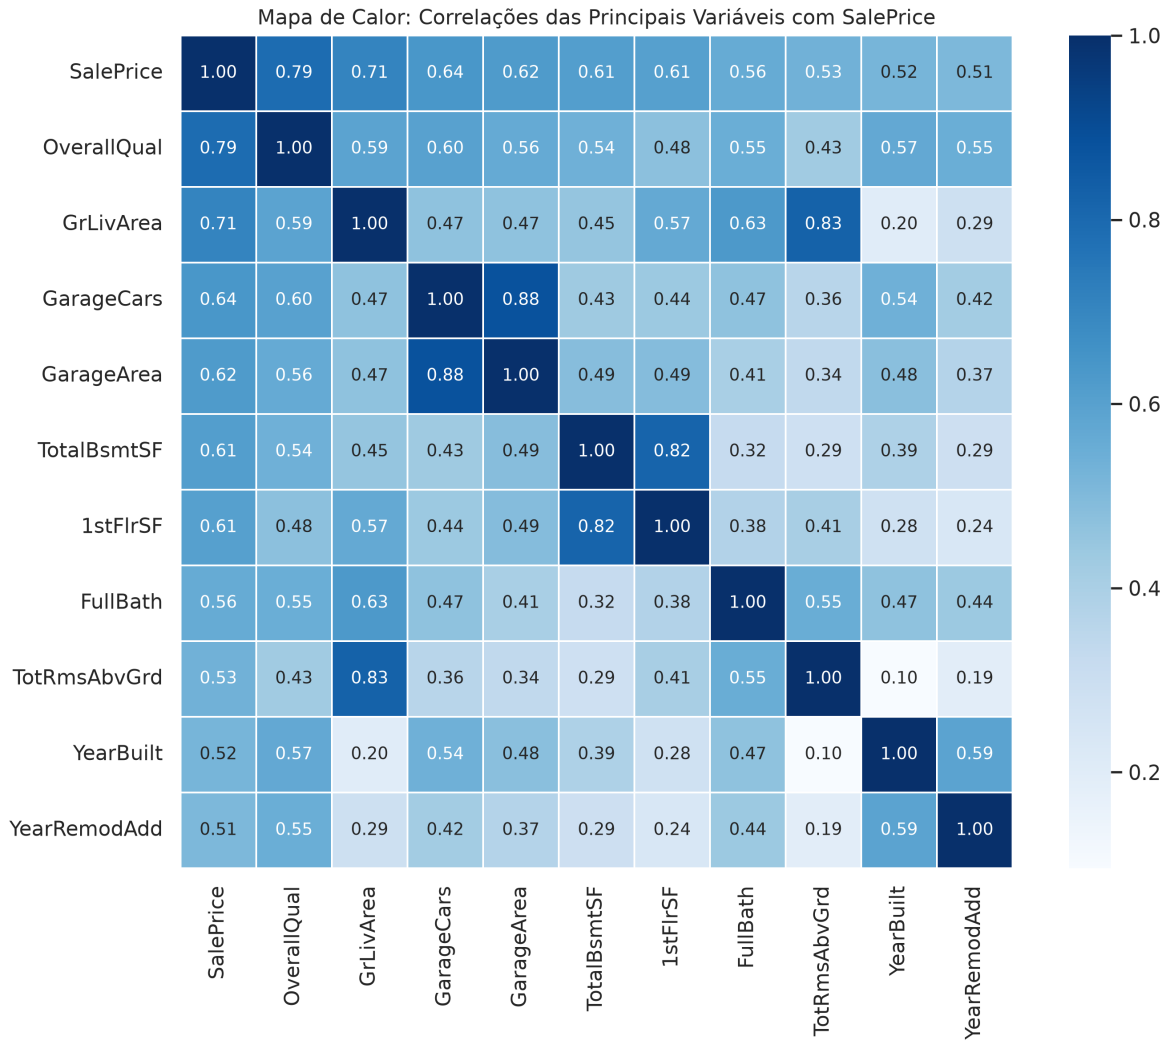
A base de treinamento House Prices reúne 1.460 vendas residenciais em Ames, Iowa, com 79 atributos explicativos, identificador e preço de venda. A análise cria atributos, examina sua relação com `SalePrice`, compara importâncias em uma floresta aleatória e usa PCA para visualizar dimensões numéricas.

2. Distribuição e correlações

O preço médio é US$ 180.921,20, a mediana US$ 163.000 e o desvio padrão US$ 79.442,50. A assimetria de 1,88 indica cauda à direita: poucos preços altos elevam a média. O intervalo observado vai de US$ 34.900 a US$ 755.000.



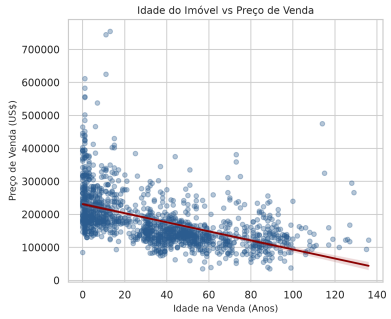
Entre as variáveis numéricas originais, `OverallQual` tem correlação de Pearson 0,791 com o preço; `GrLivArea`, 0,709; `GarageCars`, 0,640; e `TotalBsmtSF`, 0,614. São associações lineares na amostra, não efeitos causais.

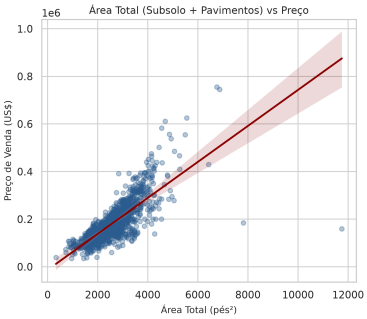


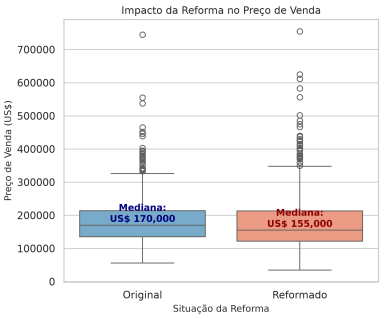
3. Engenharia de recursos

- `HouseAge = YrSold - YearBuilt` mede a idade na venda. A hipótese é que idade e estado do imóvel se relacionem ao preço; a correlação observada é -0,523. A idade não mede conservação diretamente.
- `TotalArea = TotalBsmtSF + 1stFlrSF + 2ndFlrSF` soma áreas dos pavimentos e do subsolo. A hipótese é que a área construída se associe ao preço; a correlação é 0,782. O total inclui subsolos que não são necessariamente habitáveis.
- `IsRemodeled` indica que o ano de reforma difere do ano de construção. O boxplot compara preços dos grupos, sem controlar idade, localização ou qualidade; não estima o retorno de uma reforma.

Os atributos derivados resumem informação já disponível. Preservar as colunas originais permite compará-las com as novas, embora a correlação entre elas dificulte atribuir importância exclusiva a uma delas.



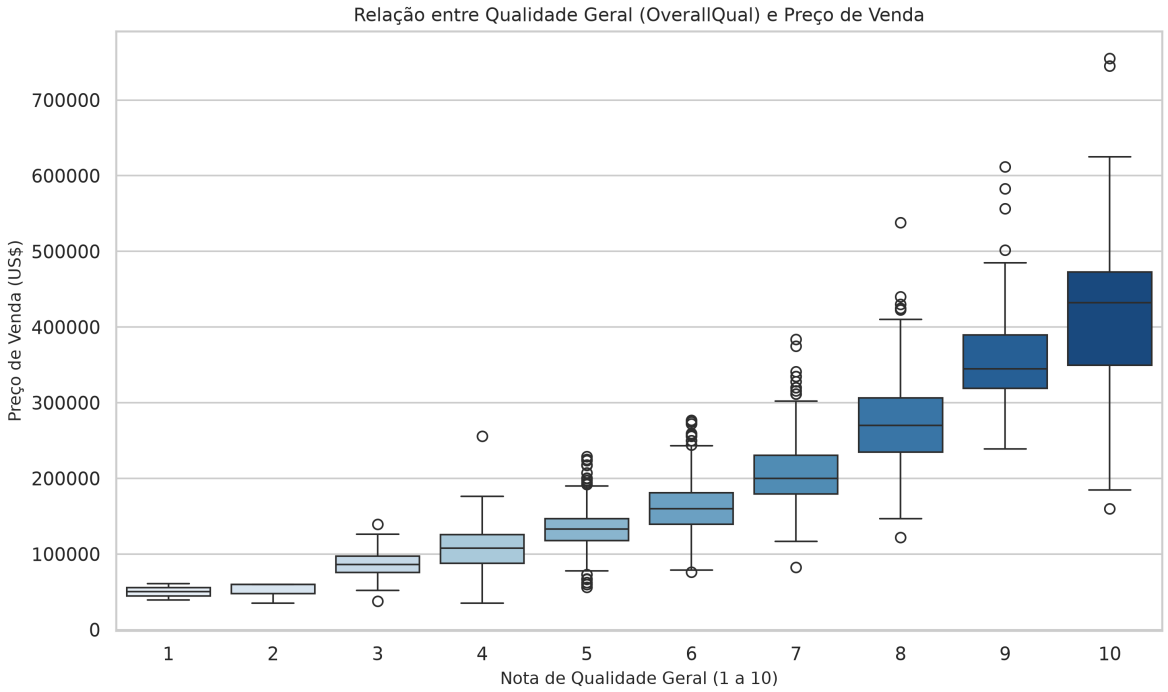




4. Variáveis ordinais e ausências

`ExterQual`, `BsmtQual` e `KitchenQual` recebem códigos de 1 a 5 para preservar a ordem de qualidade; a ausência de subsolo recebe 0. A codificação ordinal é compacta, mas modelos métricos podem interpretar como iguais distâncias que não foram medidas. One-Hot Encoding evita essa suposição, ao custo de mais colunas.

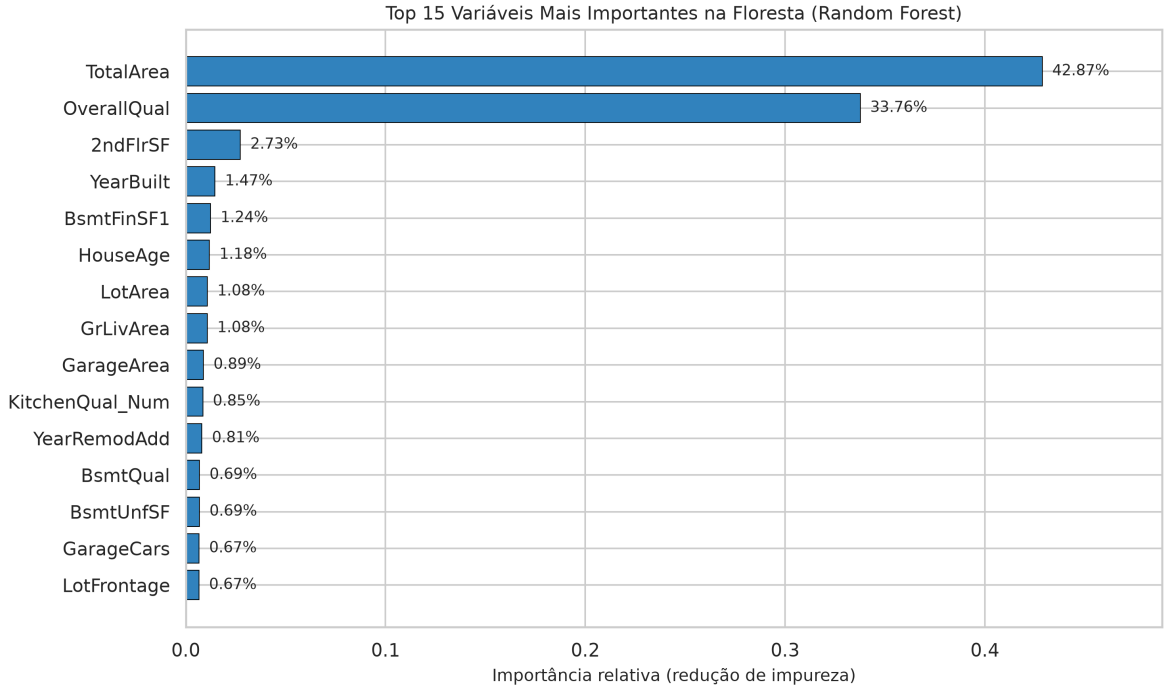
`OverallQual` já é numérica e ordenada. A mediana de `SalePrice` cresce de US$ 133.000 na nota 5 para US$ 200.141 na nota 7 e US$ 345.000 na nota 9. As distribuições se sobrepõem: qualidade não explica o preço isoladamente.



Nos campos `Alley`, `PoolQC`, `Fence`, `FireplaceQu` e `GarageType`, a documentação usa ausência para indicar que o imóvel não possui o recurso; o notebook cria categorias explícitas. Para o ranking, outras categorias ausentes recebem um marcador e valores numéricos recebem a mediana. O CSV exportado conserva ausências em outras colunas: ele é um conjunto enriquecido para exploração, não uma matriz inteiramente imputada. A causa de cada ausência remanescente não foi determinada.

5. Seleção de características

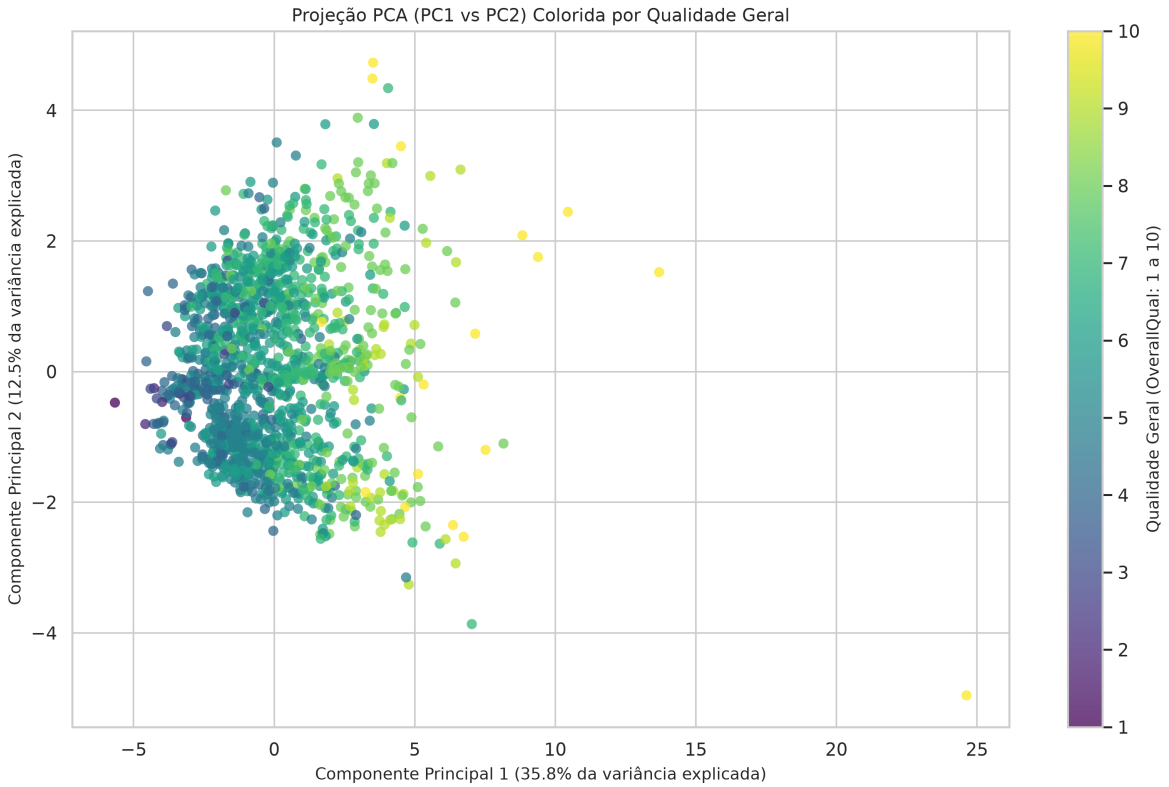
O Random Forest usa os preditores originais e criados, excluindo `Id`. A importância das categorias codificadas é somada por variável de origem. Na amostra, `TotalArea` responde por 42,87% da redução de impureza, `OverallQual` por 33,76% e `HouseAge` por 1,18%; `IsRemodeled` tem cerca de 0,05%. A medida depende dos demais atributos presentes: áreas e qualidade correlacionadas podem dividir importância. Muitas categorias ou pontos de corte também podem favorecer um atributo.



O ranking descreve um modelo ajustado à amostra inteira; ele não demonstra efeito causal nem desempenho em imóveis novos. Para comparação preditiva, imputação, codificação e seleção devem ser ajustadas apenas nos dados de treino, com teste separado.

6. PCA e interpretação conjunta

O PCA foi ajustado a 14 variáveis numéricas padronizadas. PC1 explica 35,79% da variância e PC2 12,53%; juntos retêm 48,32%. A projeção mostra um gradiente de qualidade, com sobreposição entre grupos. O restante da variância não aparece no plano; as cores representam `OverallQual`, que não integra os 14 atributos usados no ajuste.



A correlação e a importância do modelo apontam uma associação entre área e preço na amostra, enquanto o PCA resume a variação das áreas sem usar o preço. Para avaliar imóveis, esses resultados sugerem comparar propriedades semelhantes considerando área, idade e qualidade. Decisões de reforma exigem também custos e dados capazes de estimar seu efeito.

Indicador Metodológico	Valor Calculado
Total de Imóveis no Registro	1460
Preço Médio de Venda (SalePrice)	US$ 180,921.20
Preço Mediano de Venda (SalePrice)	US$ 163,000.00
Desvio Padrão (SalePrice)	US$ 79,442.50
Assimetria da Distribuição Original	1.8829 (Positiva acentuada)
Maior Correlação Linear com Preço	OverallQual (r = 0.7910)
Segunda Maior Correlação com Preço	GrLivArea (r = 0.7086)
Variável Mais Importante (Random Forest)	TotalArea (42.87%)
Segunda Variável Mais Importante	OverallQual (33.76%)
Variância Explicada pelo PC1	35.79%
Variância Explicada pelo PC2	12.53%
Variância Retida no Plano (PC1 + PC2)	48.32%
Dimensões do Dataset com Features	1460 linhas × 89 colunas

7. Recomendações e conclusão

O conjunto enriquecido `data/processed/house_prices_features.csv` mantém 1.460 linhas, 89 colunas e ausências em parte das variáveis originais. `TotalArea`, `HouseAge` e `IsRemodeled` sintetizam informações existentes e podem ser testadas contra suas componentes originais. Nenhum ganho de previsão ou retorno financeiro foi medido nesta análise.

Referências

DE COCK, Dean. Ames, Iowa: Alternative to the Boston Housing Data as an End of Semester Regression Project. *Journal of Statistics Education*, v. 19, n. 3, 2011.

KAGGLE. House Prices: Advanced Regression Techniques. Disponível em: https://www.kaggle.com/competitions/house-prices-advanced-regression-techniques. Acesso em: 5 nov. 2026.

PEDREGOSA, Fabian et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825-2830, 2011.